

BÀI TẬP: KHAI THÁC DỮ LIỆU THƯ RÁC (SMS SPAM)

- **Họ và tên:** Nguyễn Trung Chí Hào
- **MSSV:** 086205008809

```
In [1]: import pandas as pd
import collections
import re

# Đọc file dữ liệu (File SMSSpamCollection cần đặt chung thư mục với file notebook)
df = pd.read_csv('SMSSpamCollection', sep='\t', names=['label', 'message'], header=0)

# Kiểm tra dữ liệu
df.head()
```

```
Out[1]:
```

	label	message
0	ham	Go until jurong point, crazy.. Available only ...
1	ham	Ok lar... Joking wif u oni...
2	spam	Free entry in 2 a wkly comp to win FA Cup fina...
3	ham	U dun say so early hor... U c already then say...
4	ham	Nah I don't think he goes to usf, he lives aro...

```
In [2]: # 1. Đếm dòng và phân Loại
total = len(df)
counts = df['label'].value_counts()

print(f"Tổng số dòng trong dữ liệu: {total}")
print(f"Số lượng tin nhắn Ham: {counts.get('ham', 0)}")
print(f"Số lượng tin nhắn Spam: {counts.get('spam', 0)}")
```

Tổng số dòng trong dữ liệu: 5572

Số lượng tin nhắn Ham: 4825

Số lượng tin nhắn Spam: 747

```
In [3]: # Gộp tất cả message thành một chuỗi lớn và chuyển về chữ thường
all_text = " ".join(df['message']).lower()

# Tách từ: Chỉ lấy các từ là chữ cái (bỏ qua số và ký tự đặc biệt)
words = re.findall(r'\b[a-z]+\b', all_text)
```

```
In [4]: # 2. Đếm số Lượng từ
print(f"Tổng số từ trong dữ liệu: {len(words)}")
```

Tổng số từ trong dữ liệu: 85724

```
In [5]: # 3. Đếm số lần từ 'you' xuất hiện
you_count = words.count('you')
print(f"Số lần từ 'you' xuất hiện: {you_count}")
```

Số lần từ 'you' xuất hiện: 2245

```
In [6]: # 4. Đếm số lượng từ khác nhau
unique_words = set(words)
print(f"Số lượng từ khác nhau: {len(unique_words)}")
```

Số lượng từ khác nhau: 7612

```
In [7]: # 5. Liệt kê 10 từ khóa xuất hiện nhiều nhất
word_counts = collections.Counter(words)
top_10 = word_counts.most_common(10)

print("10 từ xuất hiện nhiều nhất là:")
for word, count in top_10:
    print(f"- '{word}': {count} lần")
```

10 từ xuất hiện nhiều nhất là:

- 'i': 3021 lần
- 'to': 2253 lần
- 'you': 2245 lần
- 'a': 1450 lần
- 'the': 1339 lần
- 'u': 1207 lần
- 'and': 980 lần
- 'in': 903 lần
- 'is': 897 lần
- 'me': 807 lần